

Prediction de la durée d'un trajet en taxi

Ce jeu de données est issu d'une compétition sur kaggle. Les données ont été au préalable échantillonnées et nettoyées pour les besoins de cette compétition et l'objectif était prédire la durée de chaque trajet sur la base des attributs individuels des trajets. On y retrouve les colonnes suivantes:

In [1]:

```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd
import datetime
import numpy as np
import math
import matplotlib inline
```

In [2]:

```
data = pd.read_csv('train.csv')
data
```

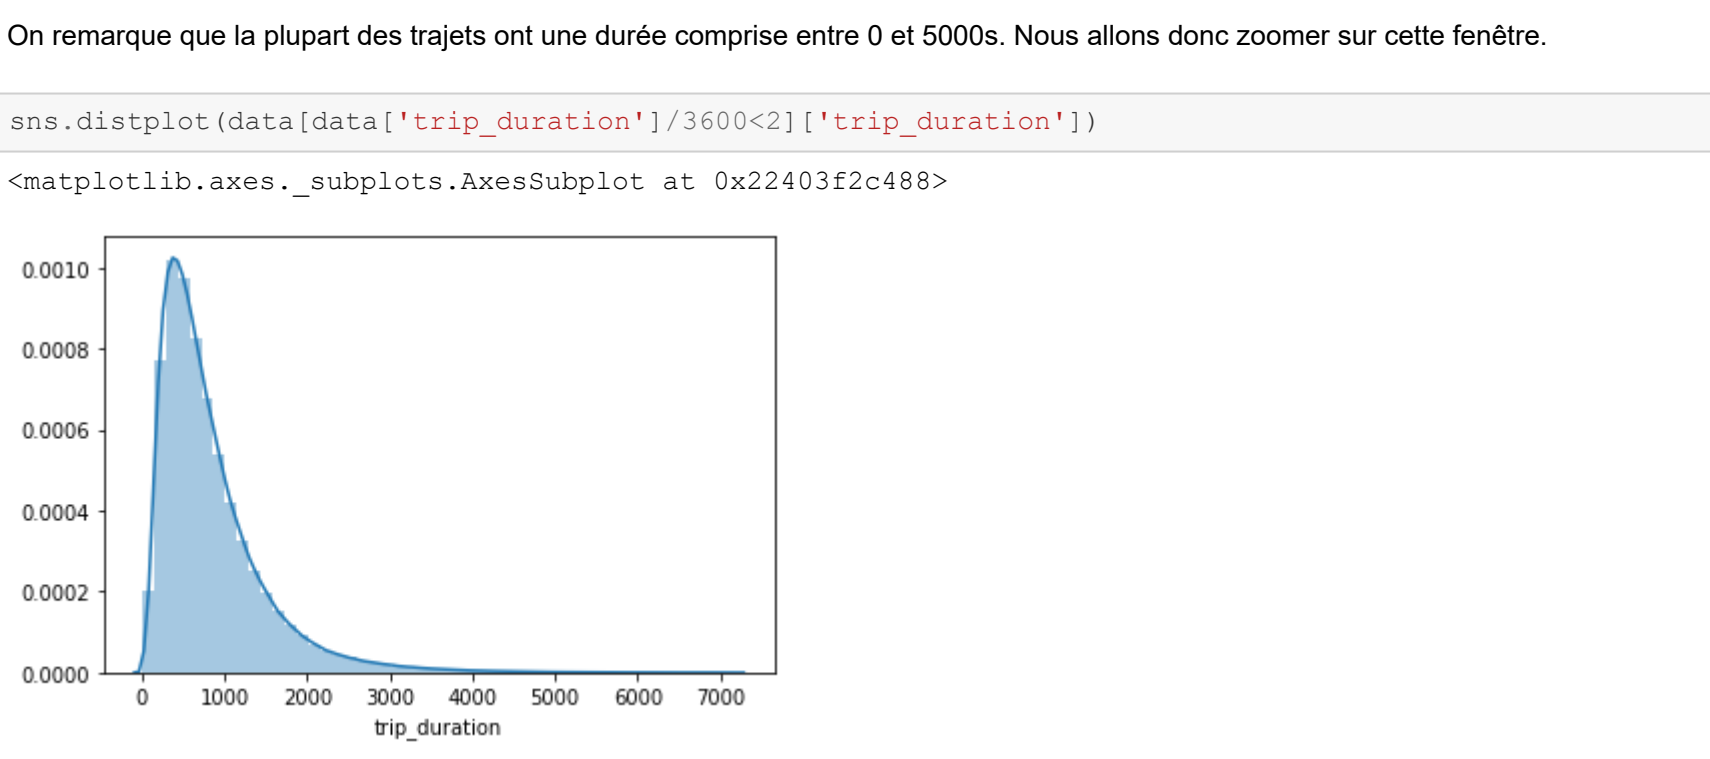
Out[2]:

	id	vendor_id	id	pickup_datetime	dropoff_datetime	passenger_count	pickup_longitude	pickup_latitude	dropoff_longitude
0	k2875421	2		2016-03-14 17:24:55	2016-03-14 17:32:30	1	-73.982155	40.767937	-73.964630
1	id2377394	1		2016-06-12 00:43:35	2016-06-12 00:54:38	1	-73.980415	40.738564	-73.999481
2	id3858529	2		2016-01-19 11:35:24	2016-01-19 12:10:48	1	-73.979027	40.763939	-74.005333
3	id3504673	2		2016-04-06 19:32:31	2016-04-06 19:39:40	1	-74.010040	40.719971	-74.012268
4	id2181028	2		2016-03-26 13:30:55	2016-03-26 13:38:10	1	-73.973053	40.793209	-73.972923
...
1458939	id2376096	2		2016-04-08 13:31:04	2016-04-08 13:44:02	4	-73.982201	40.745522	-73.994911
1458640	id104543	1		2016-01-10 07:35:15	2016-01-10 07:46:10	1	-74.000946	40.747379	-73.970184
1458641	id2304944	2		2016-04-22 06:57:41	2016-04-22 07:10:25	1	-73.959129	40.768799	-74.004433
1458642	id2714485	1		2016-01-05 15:56:26	2016-01-05 16:02:39	1	-73.982079	40.740062	-73.974632
1458643	id2109562	1		2016-04-05 14:44:25	2016-04-05 14:47:43	1	-73.979538	40.781750	-73.972809
1458644 rows x 11 columns									

In [3]:

```
# On vérifie s'il n'y a pas de valeurs manquantes dans le jeu de données.
sns.heatmap(data.isnull(),yticklabels=False,cbar=False,cmap='viridis')
```

Out[3]:

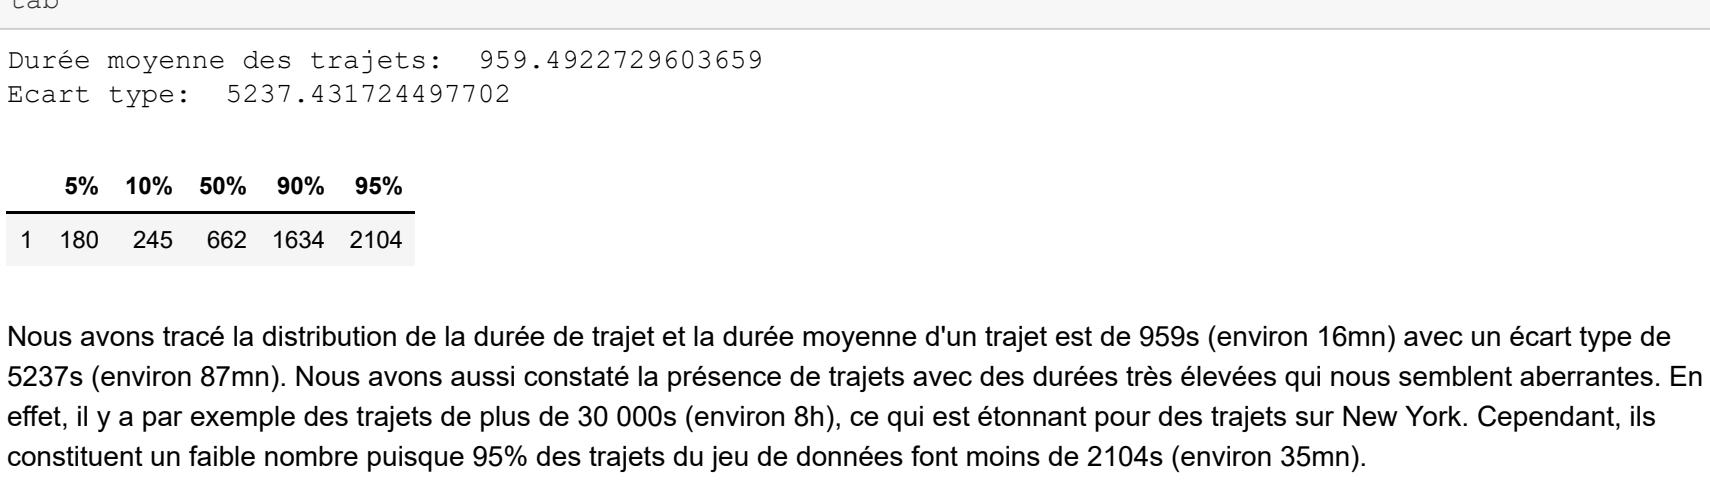


Il n'y a pas de valeurs manquantes dans le jeu de données. Pour chaque trajet, toutes les informations ont été renseignées.

In [4]:

```
# distribution de la durée de trajet
sns.distplot(data['trip_duration']/60)
```

Out[4]:

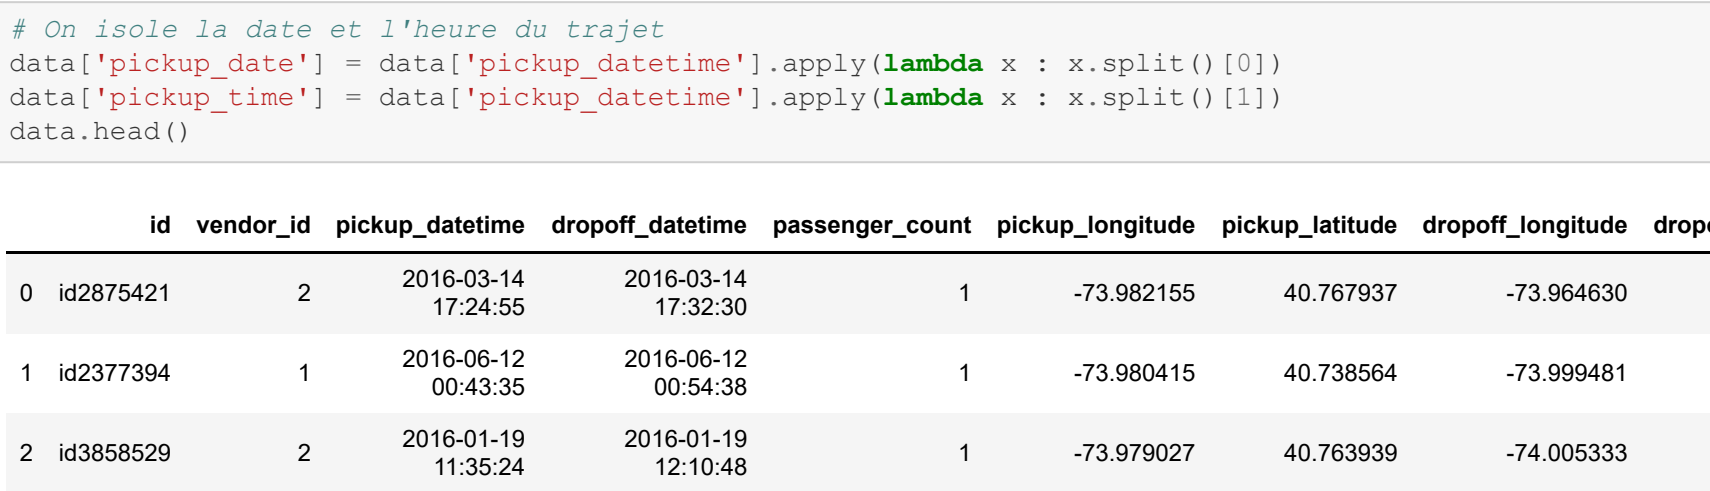


On remarque que la plupart des trajets ont une durée comprise entre 0 et 5000s. Nous allons donc zoomer sur cette fenêtre.

In [5]:

```
sns.distplot(data[data['trip_duration']/3600<2]['trip_duration'])
```

Out[5]:



In [6]:

```
quantiles = np.quantile(data['trip_duration'], (0.05,0.1,0.5,0.9,0.95))
tab = pd.DataFrame(['5%', '10%', '50%', '90%', '95%']).T
tab = tab.append(pd.DataFrame(quantiles).T, ignore_index=True)
tab.columns = tab.loc[0,1]
tab.drop(0, axis=0, inplace=True)
print('Durée moyenne des trajets: ', data['trip_duration'].mean())
print('Ecart type: ', data['trip_duration'].std())
tab
```

Durée moyenne des trajets: 959.4922729603659

Ecart type: 5237.431724497702

Out[6]:

	5%	10%	50%	90%	95%
1	180	245	662	1634	2104

Nous avons tracé la distribution de la durée de trajet et la durée moyenne d'un trajet est de 959s (environ 16mn) avec un écart type de 5237s (environ 87mn). Nous avons aussi constaté la présence de trajets avec des durées très élevées qui nous semblent aberrantes. En effet, il y a par exemple des trajets de plus de 30 000s (environ 8h), ce qui est étonnant pour des trajets sur New York. Cependant, ils constituent un faible nombre puisque 95% des trajets du jeu de données font moins de 2104s (environ 35mn).

Feature engineering

L'objectif ici est d'exploiter les informations sur les trajets pour en expliciter de nouvelles. On commence d'abord par la variable 'pickup_datetime' en séparant la date et le temps en deux variables distinctes. Ensuite, on récupère le jour de la semaine ainsi que le mois des trajets. Enfin, on isole l'heure à laquelle le compteur a été déclenché (début du trajet).

In [7]:


```
# On isole la date et l'heure du trajet
data['pickup_date'] = data['pickup_datetime'].apply(lambda x : x.split(' ')[0])
data['pickup_time'] = data['pickup_datetime'].apply(lambda x : x.split(' ')[1])
data.head()
```

Out[7]:

	id	vendor_id	id	pickup_datetime	dropoff_datetime	passenger_count	pickup_longitude	pickup_latitude	dropoff_longitude
0	k2875421	2		2016-03-14 17:24:55	2016-03-14 17:32:30	1	-73.982155	40.767937	-73.964630
1	id2377394	1		2016-06-12 00:43:35	2016-06-12 00:54:38	1	-73.980415	40.738564	-73.999481
2	id3858529	2		2016-01-19 11:35:24	2016-01-19 12:10:48	1	-73.979027	40.763939	-74.005333
3	id3504673	2		2016-04-06 19:32:31	2016-04-06 19:39:40	1	-74.010040	40.719971	-74.012268
4	id2181028	2		2016-03-26 13:30:55	2016-03-26 13:38:10	1	-73.973053	40.793209	-73.972923

In [8]:

```
# On isole le mois et on trace la distribution de la durée moyenne selon le mois
data['pickup_month'] = data['pickup_date'].apply(lambda x : x.split('-')[1])
result = data.groupby(['pickup_month'])['trip_duration'].aggregate(np.mean).reset_index().sort_values('trip_duration')
ax = sns.barplot(x='pickup_month',y='trip_duration',data=result,order=result['pickup_month'])
ax.set(xlabel='mois', ylabel='durée moyenne', title='Durée moyenne du trajet selon le mois')
plt.show()
```



D'après ce graphique, on constate que selon le mois où le trajet est effectué, sa durée moyenne varie. Le mois a donc une influence sur la durée du trajet.

In [9]:

```
# récupération du jour de la semaine où le trajet a eu lieu
correspondance = {'Mon','Tue','Wed','Thu','Fri','Sat','Sun'}
int_day = datetime.datetime(int(x.split('-')[0]), int(x.split('-')[1]), int(x.split('-')[2])).weekday()
return correspondance[int_day]
```

In [10]:

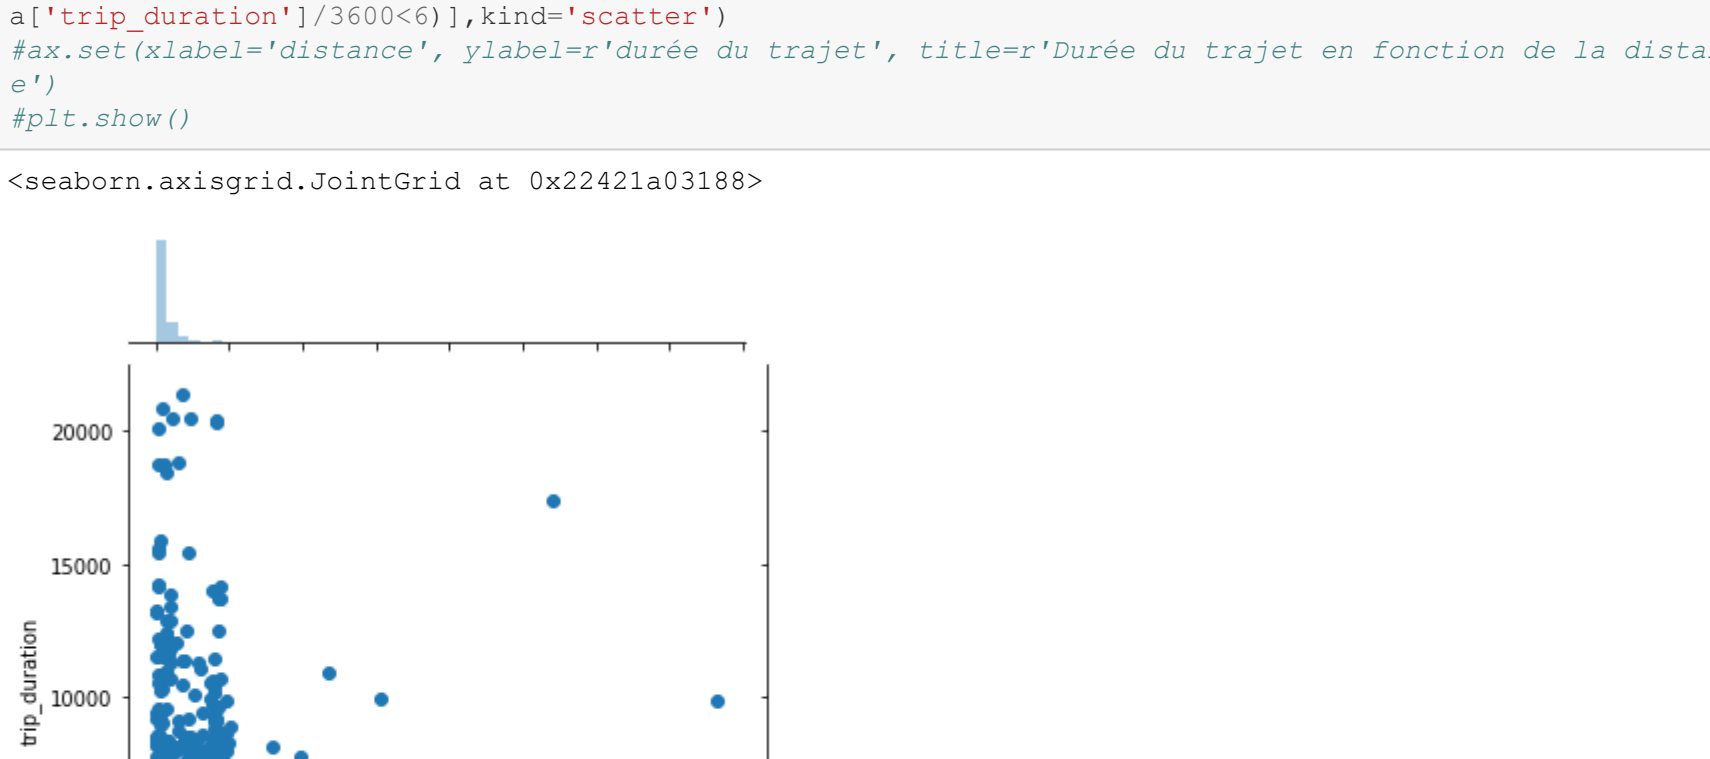
```
data['pickup_day'] = data['pickup_date'].apply(get_day)
result = data.groupby(['pickup_day'])['trip_duration'].aggregate(np.sum).reset_index().sort_values('trip_duration')
ax = sns.barplot(x='pickup_day',y='trip_duration',data=result,order=result['pickup_day'])
ax.set(xlabel='jour', ylabel='durée moyenne', title='Durée moyenne du trajet selon le jour de la semaine')
plt.show()
```



D'après ce graphique, on remarque que le jour de la semaine a aussi une incidence sur la durée d'un trajet. En effet, le jeudi, le vendredi et le samedi sont les jours où les trajets en taxi sont susceptibles de durer plus longtemps. En revanche, le dimanche et le lundi sont les jours où les trajets en taxi sont susceptibles de durer moins longtemps.

In [11]:

```
# On isole le moment de la journée (heure) où le trajet démarre
data['pickup_hour'] = data['pickup_time'].apply(lambda x : x.split(':')[0])
result = data.groupby(['pickup_hour'])['trip_duration'].aggregate(np.mean).reset_index().sort_values('trip_duration')
ax = sns.barplot(x='pickup_hour',y='trip_duration',data=result,order=result['pickup_hour'])
ax.set(xlabel='heure de la journée', ylabel='durée moyenne', title='Durée moyenne du trajet selon l'heure de la journée')
plt.show()
```



Selon le moment de la journée où on prend le taxi, la durée moyenne du trajet diffère. Elle est plus élevée par exemple les après-midis entre 13h et 17h.

In [12]:

```
# On calcule la distance à vol d'oiseau entre le point de départ et la destination.
from math import sin, cos, sqrt, atan2, radians
def compute_distance(row):
    try:
        R = 6373.0
        lat1 = radians(row['dropoff_latitude'])
        lon1 = radians(row['dropoff_longitude'])
        lat2 = radians(row['pickup_latitude'])
        lon2 = radians(row['pickup_longitude'])
        dlat = lat1 - lat2
        dlon = lon1 - lon2
        a = sin(dlat/ 2)**2 + cos(lat1) * cos(lat2) * sin(dlon/ 2)**2
        c = 2 * atan2(sqrt(a), sqrt(1 - a))
        return R * c
    except KeyError:
        print(row)
```

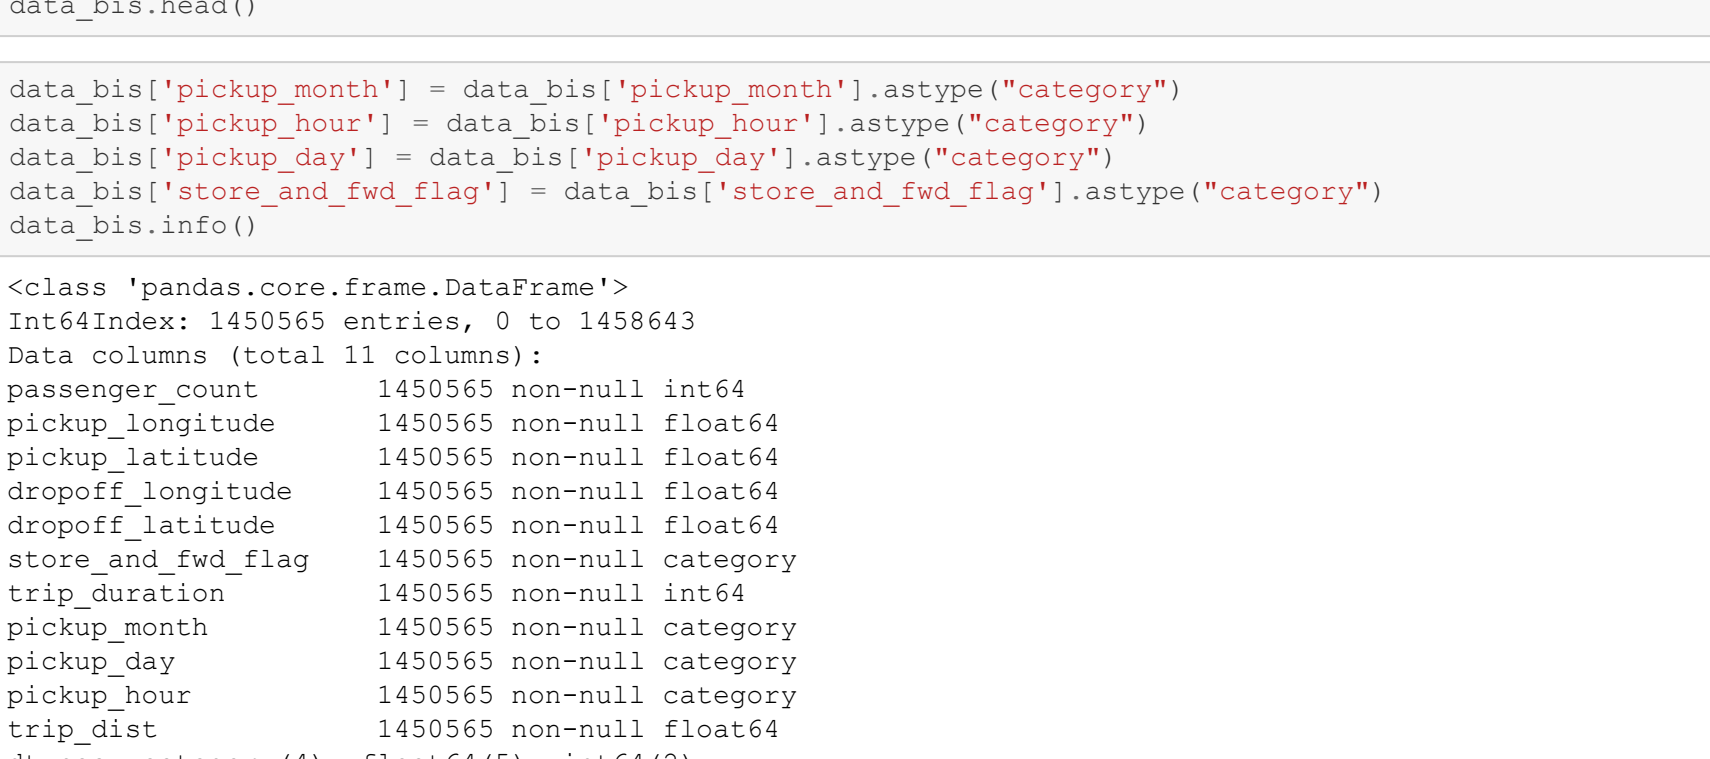
In [13]:

```
data['trip_dist'] = data.apply(compute_distance,axis=1)
```

In [14]:

```
sns.jointplot(x='trip_dist',y='trip_duration',data=data,kind='scatter')
```

Out[14]:



Ce graphique représente la durée de trajet par rapport à la distance. Comme on l'a remarqué plus haut avec la distribution de la durée des trajets, on a la confirmation que certaines d'entre eux étaient aberrants. En effet, on voit sur ce graphique que des trajets de moins de 1000m avaient une durée de plus de 1 500 000s (environ 418h). De plus on remarque des trajets de 0km, ce qui est impossible. On va donc supprimer ces valeurs par la suite. Pour se faire, nous allons calculer la vitesse moyenne de ces trajets et on supprimera les trajets avec une vitesse moyenne égale à 0km/h ou supérieure à 130km/h. Le choix du seuil à 130km/h est dû au fait que c'est la vitesse maximale autorisée dans l'état de New York.

In [15]:

```
# une fois la distance à vol d'oiseau calculée, on calcule la vitesse moyenne des trajets
data['speed'] = data['trip_dist']/data['trip_duration']/3600
data[(data['speed']<130) & (data['speed']!=0) & (data['trip_duration']/3600<6)].shape[0]/data.shape[0]*100
```

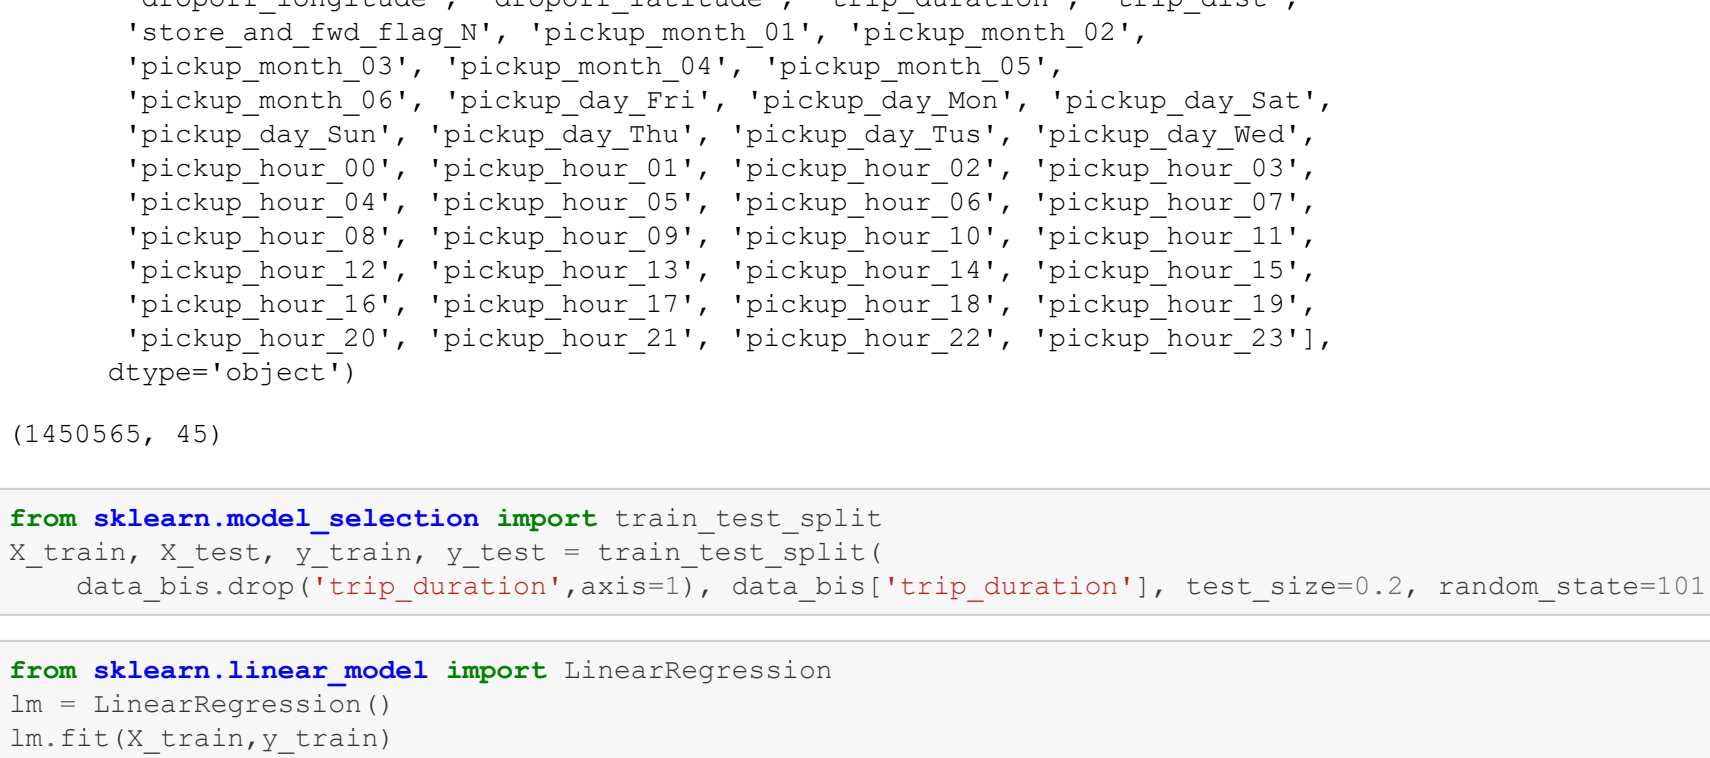
Out[15]:

```
99.44612941883008
```

In [16]:

```
sns.jointplot(x='trip_dist',y='trip_duration',data=[data[(data['speed']<130) & (data['speed']!=0) & (data['trip_duration']/3600<6)],
            data=[data[(data['speed']<130) & (data['speed']!=0) & (data['trip_duration']/3600<6)],
            kind='scatter')
ax.set(xlabel='distance', ylabel='durée du trajet', title='Durée du trajet en fonction de la distance')
plt.show()
```

Out[16]:



Nous avons tracé la durée de trajet par rapport à la distance pour les trajets de moins de 6h avec une distance supérieure à 0 et on remarque que nous n'avons pas une relation de linéarité entre la distance et la durée d'un trajet. Le choix de retenir que les trajets de moins de 7h permet de supprimer les trajets aberrants mentionnés plus haut tout en conservant presque toute la donnée (99.4 %).

Régression Linéaire

In [29]:

```
data[(data['trip_duration']/3600<7) & (data['trip_dist']<0.5)].shape[0]
```

Out[29]:

```
1456490
```

In [29]:

```
data_bis = data.copy()
data_bis = data_bis[(data_bis['speed']<130) & (data_bis['speed']!=0) & (data_bis['trip_duration']/3600<6)]
data_bis.drop(['id','vendor_id','pickup_datetime','dropoff_datetime','pickup_date','pickup_time','speed'], axis=1, inplace=True)
data_bis.head()
```

In [32]:

```
data_bis['pickup_month'] = data_bis['pickup_month'].astype("category")
data_bis['pickup_hour'] = data_bis['pickup_hour'].astype("category")
data_bis['pickup_day'] = data_bis['pickup_day'].astype("category")
data_bis['store_and_fwd_flag'] = data_bis['store_and_fwd_flag'].astype("category")
data_bis.info()
```

<class 'pandas.core.frame.DataFrame'>
Int64Index: 1450565 entries, 0 to 1458643
Data columns (total 11 columns):
passenger_count 1450565 non-null int64
pickup_longitude 1450565 non-null float64
pickup_latitude 1450565 non-null float64
dropoff_longitude 1450565 non-null float64
dropoff_latitude 1450565 non-null float64
store_and_fwd_flag 1450565 non-null category
trip_duration 1450565 non-null int64
pickup_month 1450565 non-null category
pickup_day 1450565 non-null category
pickup_hour 1450565 non-null category
trip_dist 1450565 non-null float64
dtypes: category(4), float64(5), int64(2), uint8(2)
memory usage: 94.1 MB

In [33]:

```
data_bis = pd.get_dummies(data_bis)
data_bis.columns
```

Out[33]:

```
Index(['passenger_count', 'pickup_longitude', 'pickup_latitude', 'dropoff_longitude', 'dropoff_latitude', 'trip_duration', 'trip_dist', 'store_and_fwd_flag_N', 'store_and_fwd_flag_Y', 'pickup_month_01', 'pickup_month_02', 'pickup_month_03', 'pickup_month_04', 'pickup_month_05', 'pickup_month_06', 'pickup_month_07', 'pickup_month_08', 'pickup_month_09', 'pickup_month_10', 'pickup_month_11', 'pickup_month_12', 'pickup_month_13', 'pickup_month_14', 'pickup_month_15', 'pickup_month_16', 'pickup_month_17', 'pickup_month_18', 'pickup_month_19', 'pickup_month_20', 'pickup_month_21', 'pickup_month_22', 'pickup_month_23', dtype='object']
```

In [34]:

```
data_bis.drop('store_and_fwd_flag_Y', axis=1, inplace=True)
print(data_bis.columns)
data_bis.shape
```

Index(['passenger_count', 'pickup_longitude', 'pickup_latitude', 'dropoff_longitude', 'dropoff_latitude', 'trip_duration', 'trip_dist', 'store_and_fwd_flag_N', 'pickup_month_01', 'pickup_month_02', 'pickup_month_03', 'pickup_month_04', 'pickup_month_05', 'pickup_month_06', 'pickup_month_07', 'pickup_month_08', 'pickup_month_09', 'pickup_month_10', 'pickup_month_11', 'pickup_month_12', 'pickup_month_13', 'pickup_month_14', 'pickup_month_15', 'pickup_month_16', 'pickup_month_17', 'pickup_month_18', 'pickup_month_19', 'pickup_month_20', 'pickup_month_21', 'pickup_month_22', 'pickup_month_23', dtype='object']

Out[34]:

```
(1450565, 45)
```

In [35]:

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(data_bis.drop('trip_duration',axis=1),data_bis['trip_duration'], test_size=0.2, random_state=101)
```

In [36]:

```
from sklearn.linear_model import LinearRegression
lm = LinearRegression()
lm.fit(X_train,y_train)
```

coeff_df = pd.DataFrame(lm.coef_,data_bis.drop('trip_duration',axis=1).columns,columns=['Coefficient'])
print(lm.intercept_)
-8036190596304.933

Out[36]:

	Coefficient
passenger_count	3.817280e+00
pickup_longitude	-5.848338e+01
pickup_latitude	6.282686e+02
dropoff_longitude	-6.368304e+01
dropoff_latitude	-1.608188e+03
trip_dist	1.307675e+02
store_and_fwd_flag_N	-2.892750e+01
pickup_month_01	6.820045e+12
pickup_month_02	6.820045e+12
pickup_month_03	6.820045e+12
pickup_month_04	6.820045e+12
pickup_month_05	6.820045e+12
pickup_month_06	6.820045e+12
pickup_day_Fri	-1.537307e+12
pickup_day_Mon	-1.537307e+12
pickup_day_Sat	-1.537307e+12
pickup_day_Sun	-1.537307e+12
pickup_day_Thu	-1.537307e+12
pickup_day_Tue	-1.537307e+12
pickup_day_Wed	-1.537307e+12
pickup_hour_00	-5.554731e+10
pickup_hour_01	-5.554731e+10
pickup_hour_02	-5.554731e+10
pickup_hour_03	-5.554731e+10
pickup_hour_04	-5.554731e+10
pickup_hour_05	-5.554731e+10
pickup_hour_06	-5.554731e+10
pickup_hour_07	-5.554731e+10
pickup_hour_08	-5.554731e+10
pickup_hour_09	-5.554731e+10
pickup_hour_10	-5.554731e+10
pickup_hour_11	-5.554731e+10
pickup_hour_12	-5.554731e+10
pickup_hour_13	-5.554731e+10
pickup_hour_14	-5.554731e+10
pickup_hour_15	-5.554731e+10
pickup_hour_16	-5.554731e+10
pickup_hour_17	-5.554731e+10
pickup_hour_18	-5.554731e+10
pickup_hour_19	-5.554731e+10
pickup_hour_20	-5.554731e+10
pickup_hour_21	-5.554731e+10
pickup_hour_22	-5.554731e+10
pickup_hour_23	-5.554731e+10

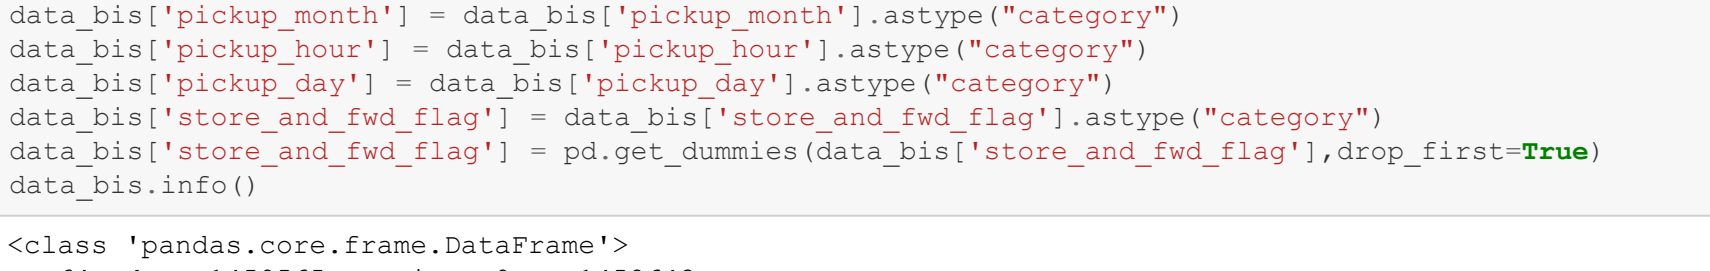
In [37]:

```
predictions = lm.predict(X_test)
```

In [38]:

```
plt.scatter(y_test,predictions)
```

Out[38]:



In [40]:

```
from sklearn import metrics
print('RMSE: ', metrics.mean_squared_error(y_test, y_pred))
print('RMSE: ', np.sqrt(metrics.mean_squared_error(y_test, y_pred))/60)
```

RMSE: 162224.32459344598

RMSE: 6.712846816685938

L'écart moyen de prédiction est égal à 6.71mn pour ce modèle.

Random Forest

In [17]:

```
data_bis = data_bis[(data_bis['speed']<130) & (data_bis['speed']!=0) & (data_bis['trip_duration']/3600<6)]
data_bis.info()
```

Out[17]:

	passenger_count	pickup_longitude	pickup_latitude	dropoff_longitude	dropoff_latitude	store_and_fwd_flag	trip_duration	pickup_month
0	1	-73.982155	40.767937	-73.964630	40.765002	N	455	0
1	1	-73.980415	40.738564	-73.999481	40.731152	N	663	0
2	1	-73.979027	40.763939	-74.005333	40.710087	N	2124	0
3	1	-74.010040	40.719971	-74.012268	40.706718	N	429	0
4	1	-73.973053	40.793209	-73.972923	40.782520	N	435	0

In [18]:

```
data_bis['pickup_month'] = data_bis['pickup_month'].astype("category")
data_bis['pickup_hour'] = data_bis['pickup_hour'].astype("category")
data_bis['pickup_day'] = data_bis['pickup_day'].astype("category")
data_bis['store_and_fwd_flag'] = data_bis['store_and_fwd_flag'].astype("category")
data_bis['store_and_fwd_flag'] = pd.get
```